

Processamento de Linguagem Natural

Engenharia Biomédica

Trabalho Prático 2

2025-2026

1 Introdução

O Trabalho Prático 2 tem como objetivo o desenvolvimento de uma plataforma Web para exploração do dataset gerado durante o TP1. Para além da visualização e manipulação dos dados, a plataforma deverá integrar um sistema de Information Retrieval (IR) aplicado a uma coleção de artigos científicos da área médica, bem como um módulo de Question Answering (QA) baseado em modelos de linguagem pré-treinados.

O trabalho organiza-se em quatro tarefas principais: enriquecimento do dataset, construção da plataforma Web, implementação do sistema de IR e integração de um modelo de QA. Aconselha-se a preparação de um caso de estudo que demonstre de forma coerente todas as funcionalidades implementadas durante a apresentação oral.

2 Tarefas

- **Enriquecer o dataset:** Utilize fontes externas, tais como websites, dicionários médicos entre outras fontes relevantes, para adicionar mais informações ao seu dataset. Pode adicionar novos conceitos ao dataset, bem como enriquecer os conceitos já existentes adicionando novos atributos, tais como sinónimos, definições, termos relacionados, domínios ou categorias. Por exemplo, "Fémur" pode ser associado à categoria "ossos".
- **Plataforma Web:** Crie uma ferramenta de visualização dos dados que permita explorar o dataset enriquecido. Esta plataforma deve permitir uma navegação adequada aos seus dados, utilizando as relações existentes entre conceitos. Por exemplo, deve ser possível organizar e ordenar os dados por diferentes atributos ou categorias. Esta ferramenta deve também permitir atualizar ou acrescentar novas informações ao conjunto de dados. Qualquer alteração feita ao sistema deve ser preservada após reinicializações do mesmo.
- **Information Retrieval:** Dada uma coleção de artigos científicos da área médica, desenvolva um sistema de IR que permita realizar pesquisas sobre os documentos dessa coleção. A metodologia implementada deve ser baseada num modelo TF-IDF ou SBERT.
Bónus: Utilize web scraping para aumentar a quantidade de documentos disponíveis na coleção.
- **Question Answering:** Integre um modelo de QA que, dado um artigo científico retornado pelo sistema de IR, forneça uma resposta a uma pergunta inserida pelo utilizador.

Para isso deve utilizar um modelo de QA baseado na arquitetura BERT disponível no HuggingFace. **Bónus:** Fazer o fine-tuning do modelo de QA em vez de usar um modelo já existente.

3 Restrições

- O projeto deve ser desenvolvido na linguagem de programação Python;
- O relatório técnico deve ser produzido em LaTeX;
- O projeto deve ser desenvolvido por grupos de alunos compostos pelos mesmos membros do trabalho prático anterior.
- Este trabalho prático deve ser entregue até ao dia anterior à data da apresentação do mesmo.

4 Deliverables

Na entrega deste projeto deve entregar os seguintes elementos:

- Código desenvolvido no âmbito deste projeto;
- Ficheiro JSON com a informação enriquecida;
- Relatório técnico do sistema desenvolvido.
- Conjunto de slides para apresentação oral do projeto (entre 10 a 15 minutos).